

Chap 3 : Théorie des tests

Organisation du chapitre 3

1 Tests statistiques

- Un exemple d'introduction
- Tests paramétriques
- Test d'adéquation
- Test d'indépendance
- Test d'ajustement de Kolmogorov

1. Tests statistiques

1.1. Un exemple d'introduction

Exemple d'introduction : les faiseurs de pluie

- Des relevés (sur longue période) : le niveau naturel des pluies dans la Beauce par an (en mm) suit une loi $\mathcal{N}(\mu = 600, \sigma = 100)$.
- Des entrepreneurs prétendent pouvoir augmenter le niveau moyen de pluie (insémination des nuages-iodure d'argent). Essai entre 1951 et 1959 :

Année	1951	1952	1953	1954	1955	1956	1957	1958	1959
mm	510	614	780	512	501	534	603	788	650

- Deux hypothèses s'affrontent :
 - L'insémination était sans effet
 - Elle augmentait le niveau moyen de pluie de 50 mm.

Hypothèses Si m désigne l'espérance mathématique de X v.a. égale au niveau annuel :

$$\begin{cases} H_0 & : & m = 600 \text{ mm} \\ H_1 & : & m = 650 \text{ mm} \end{cases}$$

1. Pour les agriculteurs : le coût ! Donc les faits observés doivent contredire nettement la validité de H_0 (l'hypothèse nulle).

Exemple d'introduction

Niveau α Niveau de probabilité ou ils sont prêts à accepter H_1 , i.e. le résultat obtenu faisait partie d'une éventualité de 5 sur 100 de se produire.

Ils prennent donc un risque de 5% de se tromper (événements rares arrivent quand même).

Test Tester la valeur m , on considère \bar{X} (moyenne des observations) qui est donc la variable de décision

Si H_0 est vraie, \bar{X} suit $\mathcal{N}(600, \frac{100}{\sqrt{9}})$

Si \bar{x} est trop grand, i.e. $\bar{x} \geq k$, avec k tel que $P(Y \geq k) = \alpha$ où $Y \sim \mathcal{N}(600, \frac{100}{\sqrt{9}})$. donc

$$k = 600 + \frac{100}{3} 1.64 = 655$$

décision Règle de décision :

- Si $\bar{X} > 655$, on rejette H_0 et accepte H_1
- Si $\bar{X} < 655$, on conserve H_0

Exemple d'introduction : les types d'erreur

Supposons que les faiseurs de pluie ont raison, alors $\bar{X} \sim \mathcal{N}(650, \frac{100}{3})$.

On commet une erreur à chaque fois que $\bar{x} < 655$, donc avec probabilité :

$$\beta := P\left(U < \frac{655 - 650}{100/3}\right) = P(U < 0.15) = 0.56$$

$\alpha = P[\text{accepter } H_1 ; \text{ alors que } H_0 \text{ vraie}]$: erreur de première espèce !

$\beta = P[\text{accepter } H_0 ; \text{ alors que } H_1 \text{ vraie}]$: erreur de deuxième espèce !

Décision \ Vérité	H_0	H_1
H_0	$1 - \alpha$	β
H_1	α	$1 - \beta$

Remarque. Les deux hypothèses ne jouent pas de rôles symétriques : - k déterminé par H_0 et α - β est déterminé par la considération supplémentaire de H_1 .

1.2. Tests paramétriques

Les Différents Tests paramétriques

Définition 4.1

Soit X_1, \dots, X_n un échantillon dont la loi est dans le modèle $(\Omega, \mathcal{A}, \{P_\theta\}_{\theta \in \Theta})$. On suppose Θ partitionné en Θ_0 et Θ_1 et on associe les hypothèses suivantes :

$$\begin{cases} H_0 : \theta \in \Theta_0 \\ H_1 : \theta \in \Theta_1 \end{cases}$$

H_0 s'appelle l'hypothèse nulle et H_1 l'hypothèse alternative.

$$\text{Test Simple } \begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta = \theta_1 \end{cases} ; \text{ Test unilaterial } \begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta > \theta_0 \end{cases} \text{ ou}$$

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta < \theta_0 \end{cases} ; \text{ Test composite } \begin{cases} H_0 : \theta \in [\theta_0, \theta_1] \\ H_1 : \theta \notin [\theta_0, \theta_1] \end{cases} \text{ ou}$$

$$\begin{cases} H_0 : \theta \notin [\theta_0, \theta_1] \\ H_1 : \theta \in [\theta_0, \theta_1] \end{cases} ; \text{ Test bilaterial } \begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases}$$

Tests paramétriques

Définition 4.2

- Erreur de première espèce, notée α , est la probabilité de rejeter à tort l'hypothèse nulle, i.e.

$$\alpha = P(\text{choisir } H_1 | H_0 \text{ est vraie})$$

- Erreur de deuxième espèce, notée β , est la probabilité de conserver à tort l'hypothèse nulle, i.e.

$$\beta = P(\text{choisir } H_0 | H_1 \text{ est vraie})$$

- La puissance d'un test, notée \mathcal{P} , est la probabilité de rejeter H_0 lorsque H_1 est vraie.

Définition 4.3

La région de Rejet d'un test, \mathcal{W} , est l'ensemble des valeurs de la statistique de test qui conduisent à rejeter H_0 au profit de H_1 .

Construction d'un test paramétrique

On a donc :

$$\alpha = P_{H_0}(\mathcal{W}), 1 - \alpha = P_{H_0}(\mathcal{W}^c), \mathcal{P} = 1 - \beta = P_{H_1}(\mathcal{W}).$$

Résumé :

Décision \ Vérité	H_0	H_1
H_0	$1 - \alpha$	β
H_1	α	$1 - \beta$

Les démarches de la construction d'un test :

- 1- choix de H_0 et H_1
- 2- détermination de la statistique de test
- 3- forme de la région de rejet
- 4- détermination de la loi de la statistique de test sous H_0 et le calcul de la région de rejet en fonction de α
- 5- calcul de la puissance
- 6- calcul de la valeur expérimental de test

Le test simple : Méthode de Neyman-Pearson

Il s'agit de maximiser la puissance $(1 - \beta)$ du test pour une valeur donnée de α risque de première espèce.

Cela revient à choisir la région critique optimale, i.e. un domaine de \mathbb{R}^n parmi l'ensemble de toutes les réalisations possibles de l'échantillon (X_1, \dots, X_n) dont la forme définira ensuite une variable statistique.

Théorème 4.1 (Neyman Pearson)

La région critique optimale W est définie par l'ensemble des points de \mathbb{R}^n tels que :

$$\frac{L(x; \theta_1)}{L(x; \theta_0)} > k_\alpha$$

ou k_α est une constante telle que $P_{H_0}(W) = \alpha$. Alors cette région W réalise le maximum de $1 - \beta$.

Test Simple sur un paramètre : moyenne d'une loi normale

connu Echantillonnage gaussien $\mathcal{N}(\mu; \sigma_0^2); \mu \in \mathbb{R}$, variance connue.

Step 1 On choisit les hypothèses

$$\text{Test simple : } \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu = \mu_1 \end{cases}$$

avec $\mu_1 > \mu_0$.

Step 2-3 Le rapport de vraisemblance est :

$$\begin{aligned} Z_n = \frac{L(X; \mu_1)}{L(X; \mu_0)} &= \exp \left(-\frac{1}{2\sigma_0^2} \left[\sum_{i=1}^n (X_i - \mu_1)^2 - \sum_{i=1}^n (X_i - \mu_0)^2 \right] \right) \\ &= \exp \left(\frac{1}{\sigma_0^2} (\mu_1 - \mu_0) \sum_{i=1}^n X_i \right) \exp \left(-\frac{n}{2\sigma_0^2} (\mu_1^2 - \mu_0^2) \right). \end{aligned}$$

Z_n est une variable aléatoire continue sous \mathbb{P}_{μ_0} . La région critique optimale au seuil α est

$$W = \left\{ (x_1, \dots, x_n); \exp \left(-\frac{1}{2\sigma_0^2} \left[\sum_{i=1}^n (x_i - \mu_1)^2 - \sum_{i=1}^n (x_i - \mu_0)^2 \right] \right) > k \right\}$$

Tests portant sur un paramètre : moyenne d'une loi normale

$$\begin{aligned} W &= \left\{ (x_1, \dots, x_n); \exp\left(\frac{1}{\sigma_0^2}(\mu_1 - \mu_0) \sum_{i=1}^n x_i\right) \exp\left(-\frac{n}{2\sigma_0^2}(\mu_1^2 - \mu_0^2)\right) > k \right\} \\ &= \left\{ (x_1, \dots, x_n); \frac{1}{n} \sum_{i=1}^n x_i > c \right\}. \end{aligned}$$

On a donc : - statistique de test : $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ - région critique (de rejet) : $W = \{\bar{X}_n > K_\alpha\}$.

Step 4 Détermination de K_α : sous l'hypothèse H_0 , \bar{X}_n suit une loi $\mathcal{N}(\mu_0, \frac{\sigma_0^2}{n})$.
Donc :

$$\begin{aligned} \mathbb{P}_{H_0}(W) &= \mathbb{P}_{H_0}\left(\frac{1}{n} \sum_{i=1}^n X_i > K_\alpha\right) = \mathbb{P}_{H_0}\left(\frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma_0} > \frac{\sqrt{n}(K_\alpha - \mu_0)}{\sigma_0}\right) \\ &= 1 - \phi\left(\frac{\sqrt{n}(K_\alpha - \mu_0)}{\sigma_0}\right) = \alpha. \end{aligned}$$

où ϕ est la fonction de répartition de la gaussienne centrée et réduite.

d'où $K_\alpha = \mu_0 + \frac{\sigma_0}{\sqrt{n}} \phi^{-1}(1 - \alpha)$.

Tests portant sur un paramètre : moyenne d'une loi normale

On rejette donc l'hypothèse H_0 si :

$$\bar{x}_n > \mu_0 + \frac{\sigma_0}{\sqrt{n}} \phi^{-1}(1 - \alpha)$$

Step 5 Puissance : sous l'hypothèse H_1 , \bar{X}_n suit une loi $\mathcal{N}(\mu_1, \frac{\sigma_0^2}{n})$, la puissance du test est définie par :

$$\mathcal{P} = \mathbb{P}_{H_1}(W) = \mathbb{P}_{H_1}(\bar{X}_n > K_\alpha) = 1 - \phi \left(\frac{\sqrt{n}(\mu_0 - \mu_1)}{\sigma_0} + \phi^{-1}(1 - \alpha) \right).$$

Tests portant sur un paramètre : moyenne d'une loi normale

Test Unilatéral

Step 1 On choisit les hypothèses

$$\text{Test unilatéral : } \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$

Step 2-3 On a toujours - statistique de test : $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ - région critique (de rejet) : $W = \{\bar{X}_n > K_\alpha\}$.

Step 4 On rejette donc l'hypothèse H_0 si :

$$\bar{x}_n > \mu_0 + \frac{\sigma_0}{\sqrt{n}} \phi^{-1}(1 - \alpha)$$

Step 5 Pour tout $\mu > \mu_0$, la puissance de test est définie donc par :

$$\mathcal{P}(\mu) = \mathbb{P}_{H_1}(W) = \mathbb{P}_{H_1}(\bar{X}_n > K_\alpha) = 1 - \phi\left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma_0} + \phi^{-1}(1 - \alpha)\right).$$

Tests portant sur un paramètre : moyenne d'une loi normale

Test Unilatéral

Step 1 On choisit les hypothèses

$$\text{Test unilatéral : } \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$$

Step 2-3 On a - statistique de test : $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ - région critique (de rejet) :

$$W = \{\bar{X}_n < K_\alpha\}.$$

Step 4 Détermination de K_α : sous l'hypothèse H_0 , \bar{X}_n suit une loi $\mathcal{N}(\mu_0, \frac{\sigma_0^2}{n})$. Il vient donc :

$$\begin{aligned} \mathbb{P}_{H_0}(W) &= \mathbb{P}_{H_0}(\bar{X}_n > K_\alpha) = \mathbb{P}_{H_0}\left(\frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma_0} < \frac{\sqrt{n}(K_\alpha - \mu_0)}{\sigma_0}\right) \\ &= \phi\left(\frac{\sqrt{n}(K_\alpha - \mu_0)}{\sigma_0}\right) = \alpha. \end{aligned}$$

$$\text{d'où } K_\alpha = \mu_0 + \frac{\sigma_0}{\sqrt{n}} \phi^{-1}(\alpha).$$

Tests portant sur un paramètre : moyenne d'une loi normale

Step 5 Puissance : sous l'hypothèse H_1 , Pour tout $\mu < \mu_0$, \bar{X}_n suit une loi $\mathcal{N}(\mu, \frac{\sigma_0^2}{n})$, la puissance du test est définie par :

$$\mathcal{P}(\mu) = \mathbb{P}_{H_1}(W) = \mathbb{P}_{H_1}(\bar{X}_n < K_\alpha) = 1 - \phi\left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma_0} + \phi^{-1}(\alpha)\right).$$

Test Bilatéral

Step 1 On choisit les hypothèses

$$\text{Test bilatéral : } \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$$

Step 2-3 On a - statistique de test : $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ - région critique (de rejet) :
 $W = \{|\bar{X}_n - \mu_0| > K_\alpha\}.$

Step 4 Détermination de K_α : sous l'hypothèse H_0 , \bar{X}_n suit une loi $\mathcal{N}(\mu_0, \frac{\sigma_0^2}{n})$.

$$\begin{aligned} \mathbb{P}_{H_0}(W) &= \mathbb{P}_{H_0}(|\bar{X}_n - \mu_0| > K_\alpha) = 1 - \mathbb{P}_{H_0}\left(\frac{\sqrt{n}K_\alpha}{\sigma_0} \leq \frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma_0} \leq \frac{\sqrt{n}K_\alpha}{\sigma_0}\right) \\ &= 2(1 - \phi(\frac{\sqrt{n}K_\alpha}{\sigma_0})) = \alpha. \end{aligned}$$

Tests portant sur un paramètre : moyenne d'une loi normale

$$\text{d'ou } K_\alpha = \frac{\sigma_0}{\sqrt{n}} \phi^{-1}\left(1 - \frac{\alpha}{2}\right).$$

On rejette donc l'hypothèse H_0 si :

$$|\bar{X}_n - \mu_0| > \frac{\sigma_0}{\sqrt{n}} \phi^{-1}\left(1 - \frac{\alpha}{2}\right)$$

Step 5 Puissance : sous l'hypothèse H_1 , Pour tout $\mu \neq \mu_0$, \bar{X}_n suit une loi $\mathcal{N}(\mu, \frac{\sigma_0^2}{n})$, la puissance du test est définie par :

$$\mathcal{P}(\mu) = 1 - \phi\left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma_0} + \phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right) + \phi\left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma_0} - \phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right)$$

Tests simple sur un paramètre : moyenne d'une loi normale

On considère un modèle d'échantillonnage gaussien $\mathcal{PN}(\mu; \sigma^2); \mu \in \mathbb{R}$ à variance inconnue. On rappelle que S_n^2 est un estimateur sans biais de σ^2 .

On choisit les hypothèses

$$\text{Test simple : } \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu = \mu_1 \end{cases}$$

avec $\mu_1 > \mu_0$.

On a - statistique de test : $\Lambda_n = \frac{\sqrt{n}(\bar{X}_n - \mu_0)}{S_n}$ - région critique (de rejet) : $W = \{\Lambda_n > K_\alpha\}$.

Détermination de K_α : sous l'hypothèse H_0 , Λ_n suit une loi T_{n-1} (loi de student à $n-1$ degrés de liberté). Il vient donc :

$$\mathbb{P}_{H_0}(W) = \mathbb{P}_{H_0}(\Lambda_n > K_\alpha) = 1 - F_{T_{n-1}}(K_\alpha) = \alpha.$$

où $F_{T_{n-1}}$ désigne la fonction de répartition de T_{n-1} .

on a donc $K_\alpha = F_{T_{n-1}}^{-1}(1 - \alpha)$. On rejette donc l'hypothèse H_0 si :

$$\bar{x}_n > \mu_0 + \frac{S_n}{\sqrt{n}} F_{T_{n-1}}^{-1}(1 - \alpha)$$

Tests portant sur un paramètre : moyenne d'une loi normale

Step 5 Puissance : sous l'hypothèse H_1 , Λ_n suit une loi T_{n-1} , la puissance du test est définie par :

$$\mathcal{P} = \mathbb{P}_{H_1}(W) = \mathbb{P}_{H_1}(\Lambda_n > K_\alpha) = 1 - F_{T_{n-1}}\left(\frac{\sqrt{n}(\mu_0 - \mu)}{s_n}\right) + F_{T_{n-1}}^{-1}(1 - \alpha)$$

Pour les autres tests : test unilatéral et test bilatéral, la méthode reste la même.

Tests simple sur un paramètre : variance d'une loi normale

connu Soit X_1, \dots, X_n un échantillon de loi $\mathcal{N}(\mu, \sigma^2)$ avec μ connu.

$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est un estimateur sans biais de σ^2 .

Step 1 On choisit les hypothèses

$$\text{Test simple : } \begin{cases} H_0 : \sigma = \sigma_0 \\ H_1 : \sigma = \sigma_1 \end{cases}$$

avec $\sigma_1 > \sigma_0$.

Step 2-3 On a - statistique de test : $\Lambda_n = \sum_{i=1}^n (X_i - \mu)^2$ - région critique (de rejet) : $W = \{\Lambda_n > K_\alpha\}$.

Step 4 Détermination de K_α : sous l'hypothèse H_0 , $\frac{\Lambda_n}{\sigma_0^2}$ suit une loi χ_n^2 :

$$\mathbb{P}_{H_0}(W) = \mathbb{P}_{H_0}(\Lambda_n > K_\alpha) = \mathbb{P}_{H_0}\left(\frac{\Lambda_n}{\sigma_0^2} > \frac{K_\alpha}{\sigma_0^2}\right) = 1 - F_{\chi_n^2}\left(\frac{K_\alpha}{\sigma_0^2}\right) = \alpha.$$

Tests portant sur un paramètre : variance d'une loi normale

où $F_{\chi_n^2}$ désigne la fonction de répartition de la loi χ_n^2 , on a donc $K_\alpha = \sigma_0^2 F_{\chi_n^2}^{-1}(1 - \alpha)$. On rejette donc l'hypothèse H_0 si :

$$\sum_{i=1}^n (x_i - \mu)^2 > \sigma_0^2 F_{\chi_n^2}^{-1}(1 - \alpha)$$

Step 5 Puissance : sous l'hypothèse H_1 , $\frac{\Lambda_n}{\sigma_1^2}$ suit une loi χ_n^2 , la puissance du test est définie par :

$$\mathcal{P} = \mathbb{P}_{H_1}(W) = \mathbb{P}_{H_1}(\Lambda_n > K_\alpha) = \mathbb{P}_{H_1}\left(\frac{\Lambda_n}{\sigma_1^2} > \frac{K_\alpha}{\sigma_1^2}\right) = 1 - F_{\chi_n^2}\left(\frac{\sigma_0^2}{\sigma_1^2} F_{\chi_n^2}^{-1}(1 - \alpha)\right)$$

Même méthode pour les autres tests.

connu On utilise la statistique de test $\Lambda_n = \sum_{i=1}^n (X_i - \bar{X}_n)^2$

1.3. Test d'adéquation

Test d'adéquation : test de χ^2

- On considère un échantillon X_1, \dots, X_n et P_θ une loi donnée où le paramètre $\theta \in \Theta \subset \mathbb{R}^d$.
- L'objectif du test d'adéquation (ou test du χ^2) est répondre à la question : les observations suivent-elles bien la loi P_θ ?
- Le problème de test à étudier est le suivant :

$$\begin{cases} H_0 : X_1, \dots, X_n \text{ suivent la loi } P_\theta \\ H_1 : X_1, \dots, X_n \text{ ne suivent pas la loi } P_\theta \end{cases}$$

Test d'adéquation : test de χ^2 - construction du test

On répartit les n observations de la v.a. X en k classes : $[e_{i-1}, e_i[$ $1 \leq i \leq k$
d'effectifs aléatoires N_i . On calcule :

$$p_i = P_{H_0}(X \in [e_{i-1}, e_i[)$$
$$D_n = \sum_{i=1}^k \frac{(N_i - np_i)^2}{np_i} = n \sum_{i=1}^k \frac{(\hat{p}_i - p_i)^2}{p_i}$$

Remarque - np_i représente l'effectif théorique - \hat{p}_i représente la probabilité estimée : $\hat{p}_i = \frac{N_i}{n}$. - D représente une distance entre la loi théorique P_θ et la loi observée. - On aurait également pu définir D_n par

$$D_n = n \sum_{i=1}^k \frac{(\hat{p}_i - p_i)^2}{\hat{p}_i}$$

Dans le cas où le paramètre θ est connu, on a le résultat suivant

Théorème Si $n \rightarrow \infty$, alors D_n est asymptotiquement distribué comme une variable de χ^2_{k-1} et ceci quelle que soit la loi de X .

Test d'adéquation : test de χ^2 - construction du test

Remarque On assimile $D_n \sim \chi_{k-1}^2$ si $np_i > 5$ pour toute classe. Dans le cas contraire, on procède à des regroupements. D'où le test χ^2 .

Rejet On rejettera H_0 si la valeur d_n constaté

$$\sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} = n \sum_{i=1}^k \frac{(\hat{p}_i - p_i)^2}{p_i} \text{ est trop grand, c-à-d si}$$

$$d_n > F_{\chi_{k-1}^2}^{-1}(1 - \alpha)$$

Dans le cas où le paramètre θ n'est pas connu, on a le résultat suivant :

Théorème Si $n \rightarrow \infty$, alors D_n est asymptotiquement distribué comme une variable de χ_{k-s-1}^2 et ceci quelle que soit la loi de X , où s désigne le nombre de paramètres estimés.

Remarque Dans le calcul des p_i , on utilise les valeurs estimées des paramètres $\hat{\theta}$.

Test d'adéquation : test de χ^2 - Exemple

Exemple Le tableau suivant présente les résultats de 500 mesures de l'erreur de pointage en dérive lors du tir à partir d'un avion sur une cible terrestre.

mesures (en radian)	effectifs
$[-4, -3[$	6
$[-3, -2[$	25
$[-2, -1[$	72
$[-1, 0[$	133
$[0, 1[$	120
$[1, 2[$	88
$[2, 3[$	46
$[3, 4[$	10

Testons l'adéquation des observations à une loi normale $\mathcal{N}(\mu, \sigma^2)$ avec un risque $\alpha = 0.05$.

Test d'adéquation : test de χ^2 - Exemple

- Pour $i = 1, \dots, 8$ notons c_i le centre de la i -ème classe. Les estimateurs de μ et de σ^2 sont donnés par :

$$\hat{\mu} = \frac{1}{500} \sum_{i=1}^8 n_i c_i = 0.168; \quad \hat{\sigma}^2 = \frac{1}{500} \sum_{i=1}^8 n_i (c_i - \hat{\mu})^2 = 2.098$$

- Sous H_0 , on a

$$p_i = \phi\left(\frac{e_i - \hat{\mu}}{\hat{\sigma}}\right) - \phi\left(\frac{e_{i-1} - \hat{\mu}}{\hat{\sigma}}\right)$$

où ϕ désigne la fonction de répartition de $\mathcal{N}(0,1)$.

- On rejette donc l'hypothèse H_0 si

$$D > F_{\chi_{8-2-1}^2}^{-1}(1 - 0.05) = F_{\chi_5^2}^{-1}(0.95) = 11.07.$$

- D'après calcul, on trouve $D = 3.524$. Donc, on accepte l'hypothèse H_0 .

1.5. Test d'indépendance

Test d'indépendance

- Soit (X, Y) un couple de v.a à valeurs dans $\{1, \dots, r\} \times \{1, \dots, s\}$. Soit $((X_i; Y_i); 1 \leq i \leq n)$ un n-échantillon de (X, Y) .
- On note $p_{ij} = P_{H_0}(X_1 = i, Y_1 = j)$, et les marginales

$$p_{i.} = \sum_{j=1}^s p_{ij}, \quad p_{.j} = \sum_{i=1}^r p_{ij}$$

- On souhaite vérifier si les variables X et Y sont indépendantes.
- On étudie le test suivant

$$\begin{cases} H_0 : p_{ij} = p_{i.} p_{.j} \\ H_1 : p_{ij} \neq p_{i.} p_{.j} \end{cases}$$

- On note les occurrences

$$N_{ij} = \sum_{k=1}^n \mathbf{1}_{X_k=i, Y_k=j}; \quad N_{i.} = \sum_{k=1}^n \mathbf{1}_{X_k=i}, \quad N_{.j} = \sum_{k=1}^n \mathbf{1}_{Y_k=j}$$

Test d'indépendance : construction du test

- La statistique du test est :

$$D_n = \sum_{i=1}^r \sum_{j=1}^s D_{ij} = \sum_{i=1}^r \sum_{j=1}^s \frac{(N_{ij} - n\hat{p}_{i.}\hat{p}_{.j})^2}{n\hat{p}_{i.}\hat{p}_{.j}} = \sum_{i=1}^r \sum_{j=1}^s \frac{(N_{ij} - \frac{N_{i.}N_{.j}}{n})^2}{\frac{N_{i.}N_{.j}}{n}}$$

- D représente la distance entre le tableau observé et le tableau théorique. Sous H_0 , D_n suit une loi de $\chi^2_{(s-1)(r-1)}$
- Pour $\alpha \in]0,1[$ donné, on rejette donc l'hypothèse H_0 si

$$D > F_{\chi^2_{(r-1)(s-1)}}^{-1}(1 - \alpha)$$

1.6. d'ajustement de Kolmogorov

Test de Kolmogorov

- Test non-paramétrique d'ajustement à une distribution entièrement spécifiée de fonction de répartition $F(x)$.
- Soit X_1, \dots, X_n un échantillon de loi inconnue P de fonction de répartition F supposée continue. L'objectif du test de Kolmogorov est l'ajustement de la loi inconnue P à une loi connue P_0 de fonction de répartition continue F_0 .
- Le problème de test à étudier est le suivant :

$$\begin{cases} H_0 : & F = F_0 \text{ (} F_0 \text{ connue)} \\ H_1 : & F \neq F_0 \end{cases}$$

- On introduit d'abord F_n la fonction de répartition empirique associée à l'échantillon X_1, \dots, X_n .

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{]-\infty, x[}(X_i)$$

Test de Kolmogorov : construction du test

- F_n est un estimateur sans biais de F , en effet :

$$E[F_n(x)] = \frac{1}{n} \sum_{i=1}^n E[\mathbf{1}_{]-\infty, x]}(X_i)] = P(X_1 < x) = F(x)$$

- D'après le Théorème Glivenko-Cantelli (admis)

$$\sup_{y \in \mathbb{R}} |F_n(y) - F(y)| \rightarrow 0, \text{ p.s. quand } n \rightarrow \infty.$$

- En particulier, si l'on suppose de plus que F est continue, alors

$$\sqrt{n} \sup_{y \in \mathbb{R}} |F_n(y) - F(y)| \rightarrow W \text{ en loi, quand } n \rightarrow \infty.$$

- W est indépendante de F et admet comme fonction de répartition :

$$K(y) := \sum_{i=-\infty}^{+\infty} (-1)^k \exp(-2k^2 y^2)$$

Test de Kolmogorov : construction du test

- La statistique du test est :

$$D_n = \sqrt{n} \sup |F_n(x) - F_0(x)|$$

- Sous H_0 , (d'après les résultats de Glivenko - Kolmogorov en théorie de l'échantillonnage) D_n est asymptotiquement distribué comme suit :

$$P(D_n < y) \rightarrow K(y) = \sum_{i=-\infty}^{+\infty} (-1)^k \exp(-2k^2 y^2)$$

- La fonction K a été tabulée et fournit donc la région de rejet :

$$D_n > K^{-1}(1 - \alpha)$$